

$$\frac{\partial \hat{y}_i}{\partial z_i} = \begin{bmatrix} \frac{\partial \hat{y}_1}{\partial z_i} \\ \vdots \\ \frac{\partial \hat{y}_i}{\partial z_i} \\ \vdots \\ \frac{\partial \hat{y}_C}{\partial z_i} \end{bmatrix} \Rightarrow \frac{\partial \hat{y}_i}{\partial z_i} = \frac{\partial}{\partial z_i} \left(\frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \right)$$

$$= \frac{e^{z_i} (\sum_{j=1}^C e^{z_j}) - e^{z_i} \times e^{z_i}}{(\sum_{j=1}^C e^{z_j})^2}$$

$$= \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \times \frac{(\sum_{j=1}^C e^{z_j}) - e^{z_i}}{\sum_{j=1}^C e^{z_j}}$$

$$= \text{softmax}(z_i) \times \left(1 - \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \right)$$

$$\Rightarrow \frac{\partial \hat{y}_i}{\partial z_i} = \text{softmax}(z_i) \times \left(1 - \text{softmax}(z_i) \right)$$


$$2) \frac{\partial \hat{y}_j}{\partial z_i}, j \neq i \Rightarrow = \frac{-e^{z_i} e^{z_j}}{(\sum_{j=1}^C e^{z_j})^2} = -1 \times \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \times \frac{e^{z_j}}{\sum_{j=1}^C e^{z_j}}$$

$$\Rightarrow \frac{\partial \hat{y}_j}{\partial z_i} = -\text{softmax}(z_i) \times \text{softmax}(z_j), j \neq i$$

($j \neq i$) $\hat{y}_j = z_i$ نهاده بـ $\hat{y}_i - z_i$ و نهاده بـ \hat{y}_i نهاده بـ z_i نهاده بـ \hat{y}_j

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum e^{z_j}} : \text{نامه نهاده بـ } (j \neq i) z_j \text{ نهاده بـ } z_i$$

$$\Rightarrow \frac{\hat{y}_i}{e^{z_i} + \sum_{j \neq i} e^{z_j}} = \frac{e^{z_i}}{e^{z_i} + A} \rightarrow \text{نامه A}$$



$$\hat{y}_j = \frac{e^{z_j}}{\sum e^{z_i}} = \frac{e^{z_j}}{e^{z_1} + \sum_{i \neq j} e^{z_i}} = \frac{e^{z_j}}{b} \cdot \frac{b}{e^{z_1} + \sum_{i \neq j} e^{z_i}}$$

این تابع sigmoid، به فرم $\frac{1}{1+e^{-x}}$ است. بازیج بآنکه نتیجه هست و

این است، پس مقصود classification است. در این مسئله می خواهیم خروجی one-hot تعلق پر رساند.

به صورت توزیع احتمال مسحون شده باشد. تابع softmax تنها در صورت که دو کلاس

دسته باشیم می تواند یک توزیع احتمال بسازد اما cross Entropy

یک توزیع احتمال برای احتمال تعلق به هر دسته هی سازد و نزیت بزرگی نسبت به sigmoid

محسوب می شود. یک موضع دیگر که از دندرار مستفاد است اف تابع می شود این است که cross entropy

بسیار بینترین تواند خروجی one-hot را محابی می نماید، ایجاد نماید. در دندرار اف می بینیم

که هر چند زیر بیست و سه تا مسأله دو بیان می کند و ۰ به صفر می نماید یعنی یک

logit از تواند تأثیر خود را روی نهای دسته های بلندار که ویژی مظلوم است. اما در sigmoid

هر خروجی نهایی نهایی به logit متناظر خود را می ستد و بالا بردن

Vazik

نهایی را صفر شد که احتمال دسته دیگر نمی شود

Subject:

Year

Month

Date

()

$$\Rightarrow \frac{e^{(z_i + \epsilon)}}{\sum_{j=1}^c e^{(z_j + \epsilon)}} = \frac{e^{\epsilon} e^{z_i}}{\sum e^{z_j} \cdot e^{\epsilon}}$$

$$= \frac{e^{\epsilon} e^{z_i}}{e^{\epsilon} \sum e^{z_j}} = \frac{e^{z_i}}{\sum e^{z_j}}$$

سؤال ۲ ب)

ت) اگر $\epsilon = \max_{j=1, \dots, c} z_j$ باشد و مسود را به عنوان z_i داشته باشیم

$z_i < 0 \rightarrow e^{z_i} \ll 1$ دلیلی از صفر سازی داده نیست:

د) باعث مسورد قدرت محسوب شود در نتیجه نهایی عدد شدن و overflow

$$P(y|x|\theta) = P(y|x, \theta) \underbrace{P(x)}_{\text{باخی از پارامترهاست}} : \text{likelihood}$$

چون باخی از پارامترهاست، ثابت است دل مسورد

مسند سانگ تائیری ندارد

$$\Rightarrow P(y|x, \theta) = \prod_{i=1}^c \hat{y}_i^{y_i} \rightarrow \text{برابر بقدرات one-hot} \rightarrow \text{و است}$$

$$\Rightarrow \text{log likelihood: } \log \left(\prod_{i=1}^c \hat{y}_i^{y_i} \right) = \sum_{i=1}^c y_i \log(\hat{y}_i)$$

است این معادل cross-entropy نیز نامی نیز

کن معادل محسوب شود log likelihood است

Vazik

Subject: _____
 Year _____ Month _____ Date _____

$$L_{CE}(y, \hat{y}) = - \sum_{i=1}^c y_i \log(\hat{y}_i) \quad (\text{سوال دوچ})$$

$$= - \sum_{i=1}^c y_i \log \frac{e^{z_i}}{\sum_j e^{z_j}} = - \sum_{i=1}^c y_i (\log e^{z_i} - \log \sum_j e^{z_j}) = - \sum_{i=1}^c y_i (z_i - \log \sum_j e^{z_j})$$

$$L_{MSE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^c (y_i - \hat{y}_i)^2 = \frac{1}{n} \sum_{i=1}^c (y_i - \frac{e^{z_i}}{\sum_j e^{z_j}})^2$$

$$L_{CE}(y, \hat{y}) = - \sum_{i=1}^c y_i \log \frac{e^{z_i}}{\sum_j e^{z_j}} = - \sum_{i=1}^c y_i (z_i - \log \sum_j e^{z_j}) \quad (8)$$

$$\Rightarrow \frac{\partial L}{\partial z} = \begin{bmatrix} \frac{\partial L}{\partial z_1} \\ \frac{\partial L}{\partial z_2} \\ \vdots \\ \frac{\partial L}{\partial z_c} \end{bmatrix}^T = -z_y + \log \sum_j e^{z_j} \rightarrow$$

و نتیجه شماره بر حسب درست
است حرکت بازای بقیه، مغایر سود

$y_i = y$ و $\hat{y}_i \neq y$ ساتھ باید باشد، تو (i=y)

$$\Rightarrow \frac{\partial L}{\partial z_i}, (i=y) \Rightarrow \frac{\partial L}{\partial z_i} = 1 + \frac{e^{z_i}}{\sum_j e^{z_j}} = 1 + \hat{y}_i = -y_i + \hat{y}_i$$

$$\Rightarrow " , (i \neq y) \Rightarrow \frac{\partial L}{\partial z_i} = 0 + \frac{e^{z_i}}{\sum_j e^{z_j}} = 0 + \hat{y}_i = -y_i + \hat{y}_i$$

$y_i \neq y$ ساتھ صفر است، حاکم

\Rightarrow با توجه دلایل در درستی دو حالت درست برداری ممکن

$$\frac{\partial L}{\partial z} = \begin{bmatrix} \frac{\partial L}{\partial z_1} \\ \vdots \\ \frac{\partial L}{\partial z_i} \\ \vdots \\ \frac{\partial L}{\partial z_c} \end{bmatrix}^T = \begin{bmatrix} \hat{y}_1 - y_1 \\ \vdots \\ \hat{y}_i - y_i \\ \vdots \\ \hat{y}_c \end{bmatrix}^T = \left(\begin{bmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_i \\ \vdots \\ \hat{y}_c \end{bmatrix} - \begin{bmatrix} y_1 \\ \vdots \\ y_i \\ \vdots \\ y_c \end{bmatrix} \right)^T = (\hat{y} - y)^T$$

Subject:

Year

Month

Date

()

$$L_{MSE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n \left(y_i - \frac{e^{z_i}}{\sum e^{z_j}} \right)^2$$

(with \hat{y}_i)

$$= \frac{1}{n} \left[(y_1 - \frac{e^{z_1}}{\sum e^{z_j}})^2 + \dots + (y_n - \frac{e^{z_n}}{\sum e^{z_j}})^2 \right]$$

$$\Rightarrow \frac{\partial L}{\partial z_i} = \frac{\sum \left(2(y_m - \frac{e^{z_m}}{\sum e^{z_j}}) e^{z_m} e^{z_i} \right) - e^{z_i} \sum e^{z_j}}{(\sum e^{z_j})^2}$$

$$= \sum_m \left(2(y_m - \hat{y}_m) \cdot \frac{e^{z_m}}{\sum e^{z_j}} \cdot \frac{e^{z_i}}{\sum e^{z_j}} \right) - \frac{e^{z_i}}{\sum e^{z_j}}$$

$$= \sum_m (2(y_m - \hat{y}_m) \hat{y}_m \cdot \hat{y}_i) - \hat{y}_i$$


$$= \hat{y}_i \cdot 2 \sum_m ((y_m - \hat{y}_m) \hat{y}_m) - \hat{y}_i$$

$$= 2\hat{y}_i (y - \hat{y})^T \hat{y} - \hat{y}_i = \hat{y}_i (2(y - \hat{y})^T \hat{y} - 1)$$

$$\Rightarrow \frac{\partial L}{\partial z} = \begin{bmatrix} \hat{y}_1 (2(y - \hat{y})^T \hat{y} - 1) \\ \vdots \\ \hat{y}_i (2(y - \hat{y})^T \hat{y} - 1) \\ \vdots \\ \hat{y}_n (2(y - \hat{y})^T \hat{y} - 1) \end{bmatrix}$$

$$= (2(y - \hat{y})^T \hat{y} - 1) \underbrace{\begin{bmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_i \\ \vdots \\ \hat{y}_n \end{bmatrix}}_{\hat{y}} = (2(y - \hat{y})^T \hat{y} - 1) \hat{y}$$

ب عقب انتشار دیم



سوال ۳. روش قابی و جزو طبقه ده با استفاده از تابع

sigmoid، تابع درد نظر نبا فضای متعدد خفروت دهنل

step تجیی می زند، اما با توجه به آنکه در صورت سوال نتایج معاد قابل خواسته

شده است، بیک مدل مناسب برای توان تقریب ها با یک خط بالا باشد. بطور ملی عبارت

$$f(x) = \begin{cases} a_1x + b_1 & -1 \leq x \leq m \\ a_2x + b_2 & m \leq x \leq n \\ a_3x + b_3 & n \leq x \leq k \\ a_4x + b_4 & k \leq x \leq l \\ a_5x + b_5 & l \leq x \leq 2 \end{cases}$$

برای آنکه هر دفعه از پیرا لینم می باشد


خطای MSE را میان خوبی مدل

که در باره های مختلف یک خط است را نسبت به تابع \sin کمینه می شود.

خنث

برای ساختن مدل از ۳ نورون با تابع فعالساز relu استفاده می شود. حال وزن ها

در باره $x \leq m$ است.




باید در باره های پاسیر که در استاد آن نورون ۲ درسن

$w_1x + b_1 > 0$ یعنی w_1 (فعال) است.

حال در بازه بعدي يعني $x < m$ ، نورون يك د ر فاعلها باید رايش باشد، وزنها
با هم صرفاً مي تيئم که نورون عدم رايش باشد و باقی خاموش. و به همین ترتيب.

(پس توابع مي تيئم که $f(x) = \alpha_j x + b_j$ معادل $w_j x + b_j$ است)

براي آنکه اين شرایط مراهم باشد عمل با پارامترهاي زير پیشنهاد مي شود
با استفاده از آن بادر ترجمه شود)




مسئلہ ۴) وزن ہائی بیان لایفنی: $W^{(1)}$ و $W^{(2)}$ ماتریس
 $W^{(1)} :$ وزن ہائی بیان و بعدی لایفنی

$$W^{(1)} = \begin{bmatrix} w_1 & w_3 \\ w_2 & w_4 \end{bmatrix} = \begin{bmatrix} 0,1 & 0,2 \\ 0,15 & 0,25 \end{bmatrix}, W^{(2)} = \begin{bmatrix} w_5 & w_7 \\ w_6 & w_8 \end{bmatrix} = \begin{bmatrix} 0,3 & 0,4 \\ 0,35 & 0,45 \end{bmatrix}$$

$$i = [i_1, i_2] = [0,05, 0,15], b^{(1)} = [0,3, 0,3], b^{(2)} = [0,5, 0,5]$$

$Z^{(1)} :$ $Z^{(1)} = \text{all } \rightarrow \text{preactivation}$ معادلہ $a^{(1)} :$ لایفنی التیویشن در



حومی شدہ : $a' = g'(g(i \times w^{(1)} + b^{(1)}) \times w^{(2)} + b^{(2)})$

(ردی شدہ حرطہ بروٹ
نشان دہ شدہ است)

بروزتہ درجہ دار عملی تذہب

$$\begin{aligned} i \times w^{(1)} &= [0,05, 0,15] \begin{bmatrix} 0,1 & 0,2 \\ 0,15 & 0,25 \end{bmatrix} \\ &= [0,0275, 0,0475] \end{aligned}$$

$$1) Z^{(1)} = i \times w^{(1)} + b^{(1)} = [0,0275, 0,0475] + [0,3, 0,3] = [0,3275, 0,3475]$$

$$2) a^{(1)} = g'(i \times w^{(1)} + b^{(1)}) = \left[\frac{1}{1+e^{-0,3275}} \quad \frac{1}{1+e^{-0,3475}} \right] = [0,5812, 0,5860]$$

element-wise

$$3) a^{(1)} \times w^{(2)} = [0,5812, 0,5860] \begin{bmatrix} 0,3 & 0,4 \\ 0,35 & 0,45 \end{bmatrix} = [0,3794, 0,4962]$$

$$4) Z^{(2)} = a^{(1)} + w^{(2)} + b^{(2)} = [0,3794, 0,4962] + [0,5, 0,5] = [0,8794, 0,9802]$$

Vazik 6) $a^{(2)} = g'(Z^{(2)}) = \left[\frac{1}{1+e^{-0,8794}} \quad \frac{1}{1+e^{-0,9802}} \right]$

Subject:

Year _____ Month _____ Date _____

$$E = \frac{1}{2} \left[(-0.1 - 0.7067)^2 + (-0.9 - 0.7303)^2 \right] = (\rightarrow)$$

$$= \frac{1}{2} (0.3681 + 0.0288) = 0.1984$$

$$\nabla_O E = \begin{bmatrix} \frac{\partial E}{\partial o_1} & \frac{\partial E}{\partial o_2} \end{bmatrix} = \nabla_{o^{(2)}} E \quad \therefore \text{Back propagation}$$

$$\Rightarrow \frac{\partial E}{\partial o_j} = \frac{\partial}{\partial o_j} \left[\frac{1}{2} \sum_{k=1}^2 (o_k - t_k)^2 \right] = \frac{1}{2} \frac{\partial}{\partial o_j} (o_j^2 - 2o_j t_j + t_j^2)$$

$$= \frac{1}{2} (2o_j - 2t_j) = o_j \cdot t_j$$

$$\Rightarrow \nabla_{o^{(2)}} E = \nabla_O E = \begin{bmatrix} o_1 - t_1 & o_2 - t_2 \end{bmatrix} = \begin{bmatrix} 0.6067 & -0.1697 \end{bmatrix}$$

$$\nabla_{z^{(2)}} E = \begin{bmatrix} \frac{\partial E}{\partial z_1^{(2)}} & \frac{\partial E}{\partial z_2^{(2)}} \end{bmatrix} = \begin{bmatrix} \sum_k \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial z_1^{(2)}} & \sum_k \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial z_2^{(2)}} \end{bmatrix}$$

$$\text{sigmoid}(z_j) = \begin{bmatrix} \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} & \frac{\partial E}{\partial o_2} \frac{\partial o_2}{\partial z_2^{(2)}} \end{bmatrix}$$

$$\Rightarrow \frac{\partial o_j}{\partial z_j^{(2)}} = \frac{\partial}{\partial z_j^{(2)}} \left[\frac{1}{1+e^{-z_j^{(2)}}} \right] \Rightarrow \begin{cases} \text{مسقٌ بـ} : y = \frac{1}{1+e^{-x}} \rightarrow y' = \frac{e^{-x}}{(1+e^{-x})^2} \\ \text{Sigmoid} \end{cases}$$

$$\Rightarrow \frac{\partial o_j}{\partial z_j^{(2)}} = \sigma'(z_j^{(2)}) (1 - \sigma(z_j^{(2)})) \quad \Rightarrow y' = \frac{1}{1+e^{-x}} \cdot \frac{e^{-x}}{1+e^{-x}} = \sigma(x) (1 - \frac{1}{1+e^{-x}}) = \sigma(x) (1 - \sigma(x))$$

$$\Rightarrow \nabla_{z^{(2)}} E = \begin{bmatrix} 0.6067 \times \sigma'(0.8794) \times 1 - \sigma(0.8794) & -0.1697 \times \sigma'(0.9962) \end{bmatrix}$$

$$= \begin{bmatrix} 0.1263 & -0.0334 \end{bmatrix} \xrightarrow{\text{chain rule}} \nabla_{b^{(2)}} E = \nabla_{z^{(2)}} E \underbrace{\nabla_{b^{(1)}} z^{(2)}}_I = \nabla_{z^{(2)}} E \times I \cdot \sigma'(0.9962)$$

$$\Rightarrow \nabla_{b^{(2)}} E = \begin{bmatrix} 0.1263 & -0.0334 \end{bmatrix}$$

Vazik

Subject:

Month

Date _____ ()

$$\nabla_{W^{(2)}} E = \begin{bmatrix} \frac{\partial E}{\partial w_5} & \frac{\partial E}{\partial w_7} \\ \frac{\partial E}{\partial w_6} & \frac{\partial E}{\partial w_8} \end{bmatrix} \xrightarrow[\text{chain rule}]{} \begin{bmatrix} \nabla_{z^{(2)}} E \nabla_{w_5} z^{(2)} & \nabla_{z^{(2)}} E \nabla_{w_7} z^{(2)} \\ \nabla_{z^{(2)}} E \nabla_{w_6} z^{(2)} & \nabla_{z^{(2)}} E \nabla_{w_8} z^{(2)} \end{bmatrix}$$

$$\nabla_{w_5} z^{(2)} = \begin{bmatrix} \frac{\partial z_1^{(2)}}{\partial w_5} \\ \frac{\partial z_2^{(2)}}{\partial w_5} \end{bmatrix} = \begin{bmatrix} a_1^{(1)} \\ 0 \end{bmatrix}, \quad \nabla_{w_6} z^{(2)} = \begin{bmatrix} a_2^{(1)} \\ 0 \end{bmatrix}$$

$$\nabla_{w_7} Z^{(2)} = \begin{bmatrix} 0 \\ a_1^{(1)} \end{bmatrix}, \quad \nabla_{w_8} Z^{(2)} = \begin{bmatrix} 0 \\ a_2^{(1)} \end{bmatrix}$$

$$\Rightarrow \nabla_{W^{(2)}} E = \begin{bmatrix} \frac{\partial E}{\partial z_1^{(2)}} a_1^{(1)} & \frac{\partial E}{\partial z_2^{(2)}} a_1^{(1)} \\ \frac{\partial E}{\partial z_1^{(2)}} a_2^{(1)} & \frac{\partial E}{\partial z_2^{(2)}} a_2^{(1)} \end{bmatrix} = \begin{bmatrix} a_1^{(1)} \\ a_2^{(1)} \end{bmatrix} \begin{bmatrix} \frac{\partial E}{\partial z_1^{(2)}} & \frac{\partial E}{\partial z_2^{(2)}} \end{bmatrix}$$

$$\Rightarrow \nabla_{W^{(2)}} E = (a^{(1)})^\top \times \nabla_{Z^{(2)}} E = \begin{bmatrix} 0.5812 \\ 0.5860 \end{bmatrix} \begin{bmatrix} 0.1263 & -0.10334 \\ 0.10734 & -0.10194 \\ 0.10740 & -0.10195 \end{bmatrix}$$

$$\nabla_{\alpha^{(1)}} = \nabla_{z^{(2)}} E \times (W^{(2)})^T \quad \text{برای} \quad \nabla_{\alpha^{(1)}} E$$

$$\Rightarrow \nabla_{\alpha}^{(1)} E = \begin{bmatrix} 0,1263 & -0,0334 \end{bmatrix} \begin{bmatrix} 0,3 & 0,35 \\ 0,4 & 0,45 \end{bmatrix} = \begin{bmatrix} 0,0245 & 0,0291 \end{bmatrix}$$

$$\nabla_{z^{(1)}} E \implies \text{ sigmoid function} \Rightarrow \nabla_{z^{(1)}} E = [0.0245 \times \sigma(0.3275) \\ \times 1 - \sigma(0.3275)]$$

Vazik ✓
911 010291 x 6' (1,3475) x (1-6' (1,3475)]

Subject:

Year

Month

Date ()

$$\Rightarrow \nabla_{z^{(1)}} E = \begin{bmatrix} 0,0064 & 0,0086 \end{bmatrix} \xrightarrow[\text{شنان دارم}]{\text{مانند رک}} \nabla_{b^{(1)}} E = \begin{bmatrix} 0,0059 & 0,0070 \end{bmatrix}$$

$$\nabla_{w^{(1)}} E \xrightarrow[\text{برسی}]{\text{مانند رک}} i^T \nabla_{z^{(1)}} E = \begin{bmatrix} 0,05 \\ 0,15 \end{bmatrix} \begin{bmatrix} 0,0059 & 0,0070 \end{bmatrix}$$

$$\Rightarrow \nabla_{w^{(1)}} E = \begin{bmatrix} 0,0003 & 0,0004 \\ 0,0009 & 0,0011 \end{bmatrix}$$

$$\text{Update: } w^{(1)} = w^{(1)} - 0,4 \frac{\partial E}{\partial w^{(1)}} = \begin{bmatrix} 0,1 & 0,2 \\ 0,15 & 0,25 \end{bmatrix} - 0,4 \begin{bmatrix} 0,0003 & 0,0004 \\ 0,0009 & 0,0011 \end{bmatrix}$$

$$\Rightarrow w^{(1)} = \begin{bmatrix} 0,999 & 1,999 \\ 0,1496 & 0,2496 \end{bmatrix}.$$

$$b^{(1)} = [0,3 \ 0,3] - 0,4 [0,10059 \ 0,10070] = [0,2976 \ 0,2972]$$

$$w^{(2)} = \begin{bmatrix} 0,3 & 0,4 \\ 0,35 & 0,45 \end{bmatrix} - 0,4 \begin{bmatrix} 0,0734 & -0,10194 \\ 0,0740 & -0,10195 \end{bmatrix}$$

$$= \begin{bmatrix} 0,2706 & 0,4078 \\ 0,3204 & 0,4578 \end{bmatrix}$$

$$b^{(2)} = [0,5 \ 0,5] - 0,4 [0,1263 \ -0,0334] = [0,4475 \ 0,5134]$$

مسئلہ ② : الگ (Chain rule) از خالد استفایہ
پر نیم و مسئنہ انسنت بخوبی عملیات

$$\frac{\partial E}{\partial W(f', c', h', w')} \Rightarrow \text{convolution} \quad \frac{\partial E}{\partial O(a, b, i, j)} \cdot \frac{\partial O(a, b, i, j)}{\partial W(f', c', h', w')}$$

حل طبق صورت سوال می توان (j, i) پر صحت زیرنوشت:
Vazik

Subject:

Year

Month

Date ()

$$\Rightarrow O(a, b, i, j) = \sum_{r=0}^{C-1} \sum_{k=0}^{f_{h-1}} \sum_{f=0}^{f_{w-1}} W(b, r, k, f) \times (a, r, sxi+k, sxj+f)$$

با توجه به آنکه مسئق نسبت به پارامتر (f', c', h', w') در مسئق شده $W(f', c', h', w')$ است

$$\textcircled{I} \quad b = f'$$

$$\begin{cases} r = c' \\ k = h' \\ f = w' \end{cases}$$

$$\frac{\partial O(a, b, i, j)}{\partial W(f', c', h', w')}$$

$$= X(a, r, sxi+k, sxj+f) \textcircled{I} \equiv X(a, c', sxi+h' + sxj+w') \textcircled{II}$$

برابر است با: و در باقی موارد صفر است. در نتیجه در نهایت دریم:

$$\frac{\partial E}{\partial W(f', c', h', w')} = \sum_{a=0}^{N-1} \sum_{b=0}^{F-1} \sum_{i=0}^{O_h-1} \sum_{j=0}^{O_w-1} \frac{\partial E}{\partial O(a, b, i, j)} \cdot \frac{\partial O(a, b, i, j)}{\partial W(f', c', h', w')}$$

با توجه به آنکه در نتیج جمع روی b بروانسته شد

$$\Rightarrow = \sum_{a=0}^{N-1} \sum_{i=0}^{O_h-1} \sum_{j=0}^{O_w-1} \frac{\partial E}{\partial O(a, f', i, j)} \cdot \frac{\partial O(a, f', i, j)}{\partial W(f', c', h', w')}$$

$$\textcircled{II} \Rightarrow = \sum_{a=0}^{N-1} \sum_{i=0}^{O_h-1} \sum_{j=0}^{O_w-1} \frac{\partial E}{\partial O(a, f', i, j)} \cdot X(a, c', sxi+h', sxj+w')$$

$$\frac{\partial E}{\partial X(n', c', h', w')} = \sum_{a=0}^{N-1} \sum_{b=0}^{F-1} \sum_{i=0}^{O_h-1} \sum_{j=0}^{O_w-1} \frac{\partial E}{\partial O(a, b, i, j)} \cdot \frac{\partial O(a, b, i, j)}{\partial X(n', c', h', w')}$$

$$O(a, b, i, j) = \sum_{r=0}^{C-1} \sum_{k=0}^{f_{h-1}} \sum_{f=0}^{f_{w-1}} W(b, r, k, f) \times (a, r, sxi+k, sxj+f)$$

طبق استدلال شاپه با الف ، چون مسئله سبقت به

$$\begin{cases} \alpha = n' \\ r = c' \\ sxi + k = h' \rightarrow k = h' - sxi \\ sxj + f = w' \rightarrow f = w' - sxj \end{cases}$$

مسئله داریم:

$$\Rightarrow \frac{\delta O(a, b, i, j)}{\delta X(n', c', h', w')} = W(b, c', h' - sxi, w' - sxj)$$

و چون $a=n'$ ، مجموع روی α از مسئله برداشت می شود چون دو حالت داری

$$\frac{\delta E}{\delta X(n', c', h', w')} = \sum_{b=0}^{F-1} \sum_{i=0}^{O_n-1} \sum_{j=0}^{O_w-1} \frac{\delta E}{\delta O(n'_i b, i, j)} \cdot \frac{\delta O(a, b, i, j)}{\delta X(n', c', h', w')}$$

مسئله صفر است :

$$= \sum_{b=0}^{F-1} \sum_{i=0}^{O_n-1} \sum_{j=0}^{O_w-1} \frac{\delta E}{\delta O(n'_i b, i, j)} \cdot W(b, c', h' - sxi, w' - sxj)$$

یک مرد دیگر هم در بخش اشاره خواهد شد

Subject:

Year


Month

Date

()

مسئلہ ۶. الف) ا-تابع sigmoid: از محاط مقادیر بایع:

$$\sigma(z) = \frac{1}{1+e^{-z}}$$



$$\sigma(z) < 0.5$$

عیب:

معنار تابع sigmoid شبکه است

نیست که حق تواند سخر به مشعل زیر شود:

$a^{(k-1)}$
یا همان

*مشعل zero-centered بیوپ تابع activation: واردی لایه پنهان $a^{(k-1)}$ که در نظر می کیم

برقرار شال

که مقادیر آن همی شبکت هستند (activation تابع در لایه $k-1$) تابع sigmoid باشد

این آتفاق صماخی دارد) حال نورون دخراهن را در لایه که در تقریب داریم داشتیم:


$$z_j = \sum_{i=1}^{N^{(k-1)}} w_{ij} a_i^{(k-1)} + b^{(k)}$$

امال حی می شود که فرض می کنیم تابع sigmoid است. دلیم:

Backpropagation

$$\frac{dL}{dw_{ij}^{(k)}} = \frac{dL}{dz_j^{(k)}} \cdot \frac{dz_j^{(k)}}{d w_{ij}^{(k)}}$$

آن است



(ذهن انسان در درستی)


د نتیجہ علاوه بر این $w_{ij}^{(k)}$ برای هر i ، هم علامت با $\frac{dL}{dz_j^{(k)}}$ است که این

صرصح می شود در بهینه سازی و رسیدن به نفع optimal مشعل و محوریت ایجاد شد

ب عجزان مثال فرض می شم تهنا « وزن وردکی وحد داشته باشد . با توجه به آنکه تراویان هر

« حم علامت است ، پس بردار update تهنا می قواند به دست نیز براز

باشد ، یعنی با هر « زیار شدن یا هر » کم . واضح است که این نوع آیدیت می تواند محدودیت در رسیدن



بعنی سسر رسیدن

بعنی سسر رسیدن

به نتیجه سعیه ایجاد نماید هر را در فرض لیبر داشته باشیم


بعنی سسر رسیدن

به نفعه صور نظر نیز ایشان می شود و می توان به صورت بهینه شده

مستفیم به آن دست یافته

\Rightarrow « نتیجه تابع Sigmoid چون مقادیر مثبت (بزرگ نمود) و مقادیر منفی (مین

(الف) ۱- تابع Sigmoid : از لحاظ منطقی عیب : $(\sigma(z) = \frac{1}{1+e^{-z}} \rightarrow \sigma'(z) = \sigma(z)(1-\sigma(z))$



الآن قدرار preactivation با همان Z بزرگ باشد


باشد من شود تراویان صفر می شود و اصطلاح اسیاع با

شود . با همفر شدن تراویان ، در backdrop سر تراویان منتشر شده به لایه های ایندیکی صفر می شود

و همچوچ آیدیت روح نمی دهد . به این دست نیز vanishing gradient گویند

دیگر صور دیگر در بخش (c)

$$\tanh(z) = \frac{e^{2z} - 1}{e^{2z} + 1}$$



(الف) ۲- تابع tanh : از لحاظ قدرار تابع : همیت :

همانقدر د سمعن است مقادیر خوبی این تابع بیان داده

است د یعنی این تابع zero-centered است و از این لحاظ مطلوب است


- همین بطر لی می توان نشان داد « تابع tanh را می توان با تابع سلیمانی

$$\tanh(z) = \frac{e^{2z} - 1}{e^{2z} + 1} = 1 - \frac{2}{e^{2z} + 1} = 1 - 2e^{-2z}$$

$$\tanh(z) = \frac{e^{2z} - 1}{e^{2z} + 1}$$

$$\Rightarrow \tanh'(z) = 1 - \tanh^2(z)$$

الف) ۲- تابع \tanh از لحاظ مشتق:



عیب: مشتق این تابع نیز به ایکی مقادیر بزرگ $|z|$ معرفی شود

که صخر ب صفر شدن انتشار درایان یعنی vanishing gradient می‌شود

مزیت نسبت به Sigmoid: مشتق در \tanh نسبت به دریتر منزد شد

درایان

یعنی مقادیر z هر چقدر بزرگ شوند \tanh' دیرتر شروع به صفر شدن می‌شود (نسبت به

Sigmoid) و در نتیجه نیز قدرت مدل سازی کرد

← با این نفاسیم می‌توان لفت \tanh همراه با Sigmoid ترجیح داد می‌شود (البته این حرف کاملاً دقیق نیست). از نظر یورلوزیکن تابع sigmoid عمل بهتری برای fire بین نوون است، هر کم قدر اپلیاسیون خوبی یکنے نوون (همانکه که فعال نسبت صفر است)

$$f(x) = \begin{cases} x & x > 0 \\ 0 & x \leq 0 \end{cases} : \text{از لحاظ معdar تابع: عیب:}$$

قدرت این تابع می‌توان به صورت نامحدود بزرگ باشد و باز نه به آنقدر قدرت ای

د محاسبه درایان هاترسن در تابعی را بغير تائیددار است، اگر learning rate

مناسب نباشد، می‌تواند باعث exploding gradient شود (مقادیر بسیار بیان می‌شوند) Vazik که overflow نند

اما در \tanh و sigmoid جون مقادیر خوبی آنها محدود است بین آنفای خوب نمی‌شود

الف) (۳) ارگان مخفق: مزبت بزرگ:

$$f(x) = \begin{cases} x & x > 0 \\ 0 & \text{o.w.} \end{cases}$$

$$\rightarrow f(x) = \begin{cases} 1 & x > 0 \\ 0 & \text{o.w.} \end{cases}$$

مزبت بزرگ ReLU این است $x > 0$ به شئون آن برخلاف sigmoid و tanh باشد vanishing gradient نمی‌شود چرا که

مسئلۀ آن در ناچیه معال جهاره بک است و به خوبی باعث انتشار لاریاوار

به لایه‌های اولیه منجر شود

الف) (۴) از بحاط مخفق: عیب: عیب: دلای مسئل ReLU

است. افرض کنید w یک نورون بردار b و W تضافر با آن آپدیشن داشتند

نمایه از اینکه بردار جدید، مقدار $W^T x + b$ برای هر x ای لرچتر از صفر شود (پنهان)

$$w := w - \lambda \nabla_w L \quad \text{یا} \quad \nabla_w L \quad \text{با} \quad \text{مزبت بزرگ} \quad \text{جن دارم:}$$

$b := b - \lambda \nabla_b L$ ، مقادیر جدید b و w می‌توانند بسیار منفی شوند فاعل (از آنکه وردی

جیست، L preactivation مخفی شود). در صدقه که این آنفای مخفی شوند، کاریان ReLU

صرفی شود و در نیم هیچ آپدیشن روی w و b رخ نمی‌دهد و در نتیجه b

به ازای هر x مخفی ناچیه می‌شوند و تا این بهینه مسئل باقی توافق نمایند

Vazik

داین حالت به اصطلاح می‌گویند دودن مرده است

Subject:

Year

Month

Date

()

دلت می‌لیسیم که این مشکل با متناهی gradiente Vanishing gradient نامیده شد.

مشکلی داشت) هزینه محاسبات relu بسیار تقریباً در تابع دیر است
چراً در همان قدر و دردست با تعداد صفر را خوبی من دارد و در تابع سوت پارهیزی ناپوشش

نمی‌دهد. در تابع exp و tanh و sigmoid از بحافط محاسبات

$$\tanh(z) = \frac{e^{2z} - 1}{e^{2z} + 1}, \quad \text{هم با توجه به اینکه } \tanh'(z) = 1 - \tanh^2(z)$$

قیمتان لغنت هزینه محاسباتی tanh از sigmoid بیشتر است

مشکلی داشت) توصیفات دلخواه ایف داده شد.

دارند اما relu این مشکل را ندارد vanishing gradient

مسئلہ ۷ اف) در مقابلہ کر داں معنی مددہ است، علت این امر این آسارہ شدہ است کہ dropout می تراوند از co-adaptation دشبلڈی عصبی جلوییری کند. تعریف co-adaptation : حب شبکے عصبی، درایافی د هر پارامٹر دیافتی لند باعث می شد کہ تابع فریتہ ناپس یا بد و درمیں حال از وضعیت بقید نورون ہا آگئہ است د تبیح بک نہیں می تواند ب نوعی اسپیباہات بقید نورون ہا را جبراں کند. این بدان معنا است کہ بک سری از نورون ہا بسیار خوب افزیش می بیند و فیکرہای خوب اسخراج می نند و تأثیر بسیاری د خوبی می لذارند! اما بک سری دیگر از نورون ہا دیگر کا فیکر شلا ہمان وردی لایہ را خوبی می دھند خاص اسخراج بک نند کہ چرا کہ در ہماری با ان نورون ہاں عنین د جمیع عملکرد خوبی را روک داد train از خود سال می بھند و ب نرمی نورون ہاں عنین جو رہا رکی لشد د بے اصلہ لاح co-adaptation بین آنہا رج داده است این آفاق مخبر ب overfitting می شد چرا کہ این جنس ہماری ہا زرمی قابل تعقیب ب درکان نہست نہست و در تبیح چون تعداد قابل توجه از نورون ہا بیکر خاص اسخراج نہ رہا اند عکسر صعبیق ہنطیم سمت خراصیم داشت

با خروج کردن تعدادی نورون ها $t_{dropout}$ می شود که نورون ها نتوارد به محصور نورول

دلبری و استدای نورول و در نتیجه نمی توانند جبران استیفات را به نورول دلبری والظر نمایند

و محصور می شود و تأثیر مطلوب استخراج نمایند.

بررسی

در مقاله [Al-Baldi et al., Understanding Dropout](#), در مقاله [Al-Baldi et al., Understanding Dropout](#), در مقاله [Al-Baldi et al., Understanding Dropout](#)

یک نورون با تابع activation خطا را در نظر می گیریم و تابع MSE را به عنوان loss تجویز می کنیم.

نورون i با تابع خطا را برای مدل با dropout و مدل ensemble (همان مدل که در مقالات

$$E_{ENS} = \frac{1}{2} \left(t - \sum_{i=1}^n p_i w_i x_i \right)^2 : \text{می نویسیم} : \text{نتیجه dropout استفاده می شود}$$

$$E_D = \frac{1}{2} \left(t - \sum_{i=1}^N \delta_i w_i x_i \right)^2, \quad \delta_i \sim \text{Bernoulli}(p_i)$$

$$\frac{\partial E_{ENS}}{\partial w_i} = -t p_i x_i + w_i p_i^2 x_i^2 + \sum_{j=1, j \neq i}^n p_j w_j x_j p_i x_i : \text{حال در دیانها محاسبه می کنیم}$$

$$\frac{\partial E_D}{\partial w_i} = -t \delta_i x_i + w_i \delta_i^2 x_i^2 + \sum_{j=1, j \neq i}^n \delta_i x_i \delta_j w_j x_j$$

حال ایده ریاضی $\frac{\partial E_D}{\partial w_i}$ را حساب می کنیم (از آنجایی که

مدل اضافه می شود پس خطای مترال یک تغییر نمادنی در نظر نمی نماید که مستقیماً آن عدم تغییر نمادنی

(است)

$$\begin{aligned} \text{Expected} \left[\frac{\partial E_D}{\partial w_i} \right] &= \frac{E[\delta_i] = p_i}{\substack{\text{استقلال} \\ \delta_i, \delta_j}} - t p_i x_i + w_i p_i^2 x_i^2 + w_i \text{Var}(\delta_i) x_i^2 \\ &\quad + \sum_{j=1, j \neq i}^n p_i x_i p_j w_j x_j \\ &= \frac{\partial E_{\text{ENS}}}{\partial w_i} + w_i \text{Var}(\delta_i) x_i^2 \\ &= \frac{\partial E_{\text{ENS}}}{\partial w_i} + w_i p_i (1-p_i) x_i^2 \end{aligned}$$

← همانطور که مشخص است، تراویان در حالت dropout، تراویان شرطی بدل شدند. ←
در هر آن یک regularizer است. این در واقع تابع هزینه به صورت زیر ناپای بازگشته است.

$$= \underbrace{\frac{1}{2} \left(t - \sum_{i=1}^N p_i w_i x_i \right)^2}_{\text{loss}} + \underbrace{\frac{1}{2} \sum_{i=1}^n p_i (1-p_i) w_i^2 x_i^2}_{\text{regularization}}$$

است:

بازگشتن (backpropagation) در حالت dropout، هر یکی از نورون‌ها یا خارجش است

بازگشتن. آنرا M نویسن در شبکه داشته باشیم در جمیع می‌توان M^2 شبکه با ساختار مختلف

متضمن شد. در هر iteration در dropout یک نمره از این M^2 شبکه درست می‌شود

و یک mini Batch ری آن زیرشبکه روی یک Backpropagation بازگشتن دارد. از داده‌ها

این‌هاست و آن می‌زیرشکنند از زمان یک مدل در نظر گرفت. در زمان test

از شبکه کامل استفاده می‌کنیم که در واقع سهل‌نمای زیرشبکه‌هایی است که

که در زمان training آموزش دیوه اند. در نتیجه در زمان test انحراف بزرگی

از تابع تمام آن بزیسته ها استفاده می کنیم. این به نوعی همان کاری است

که من بعد که تابع چندین مدل استفاده می شود، البته وقت Ensemble Learning

می شویم که «dropout» وزن ها میان انحراف بزیسته ها مسترد است

و در نتیجه مدل ها مستقل از هم ندارند و در Ensemble learning بدین صورت نست

در هر Iteration یک سری از

پالا در مرحله train نورون ها را خاموش می کنیم اما در مرحله test

از تمام نورون ها بجز آنکه از آن صرفیت استفاده می کنیم و به نوعی Ensemble

کنیم استفاده می کنیم. در نتیجه این به عکس dropout در مرحله train اسید ریاضی

مقابل است. اما از خواصیم التیوئیشن نورون ها در مرحله train test

لیسان باشد که در نتیجه با ضرب نورون انتقال فاصله نورون نورون ها در activation

بصورت تقریبی این حمل را (نحو) می دعنه و در نتیجه در مرحله train test

dropout، اسید ریاضی activation ها لیسان است.

اما به طور حکی همانطور که در اینجا نشان داده شد در مرحله train و test

مختلف انجام می دهد و به عنوان مثال در هنگام نوشتن که یک شبکه ParPCO

که از dropout استفاده می کند باید به این ترتیب که فاصله نورون را درست غیرفعال کنیم

و^اي^ان^ا ، data augmentation ، dropout و^اي^ان^ا regularizer \rightarrow ت^ا

لی تری دیده می شود که آن این است که در مرحله training به نوعی نویز یا

randomness به آن اضافه نیم. چنین کاری باعث می شود که ندل یدان سمت

نروده که دارطان را حقق نمود در برابر تغیرات ورودی به نویی فقاوم نمود

و در نتیجه هاریانس مدل ناهمش یابد. پس وجود نویمی نویز من تواند در حلولمی از

randomness میں لئے۔ (وہ جو دست سعی میں بودم خود اسیت پر marginalize کیتے)

درین روئن Batch Normalization

می‌باشند و این را با این ترتیب در نظر می‌گیرند. هر minibatch می‌تواند مجموعه‌ای از n نمونه باشد که ممکن است بسیار کوچک باشد (مثلاً $n=1$) یا بسیار بزرگ باشد (مثلاً $n=1000$). در اینجا $n=100$ است.

می‌لذارد. حال با توجه به آنکه minibatch صفت تعدادی اسنایپ می‌شود،


اُنْرِيدَ داده خاص را در نظر نمی‌بریم، بسته به آنکه آن داره در درا

قرار ملید، نحوه نمایش آن \rightarrow Batch ^{Norm} \rightarrow normalize تغایر می‌سود و در

نتیجه به نهی *randomness* را مل اضافه نمود است. در برخلم تست، با توجه به آنکه

سایلنس و انحراف از بعدها را از نسل داروهای train می‌گذارد. لردهای این، اندکتریز

ث) بله. در هسته Backpropagation نیاز داریم برایم که خروجی حاصل از لایه نورده آورده است تا گزاریان را از طریق آن به عقب انتشار دعیم



مسئله ۸ - الف) فیلتر دو فیلتر در اولین جایه خود

قرار می‌گیرد، می‌باشد $N-F$ خانه را به سمت راست

حرکت می‌نماید تا صلح راست کن بر قلع راست نصیر شفیق

شود. حال آر اندازه λ همی λ فیلتر برعکس دارد $\lambda = \frac{N-F}{S}$ در نظر بگیریم، فیلتر با $\frac{N-F}{S}$

حرکت می‌نماید به لوش تصویر بررسد. بسته مقدار هم برای جایه اول فیلتر باید حساب نمی‌شود.

پس در نهایت $\frac{N-F}{S} + 1$ جایه برای هر فیلتر وجود دارد. با استدلال مشابه حالت محضی نمی‌شود.

ب) مینیموم سطح صفت. پس سایز خروجی $(\frac{N-F}{S} + 1)$ و $(1 + \frac{N-F}{S})$ حرامد بود

بعضی از این فیلترها دارند $X: (11, 224, 224)$ ابعاد \rightarrow ورودی grayscale

Network 1: $16 \times \text{conv}(5 \times 5)$: تعداد پارامترها $= (5 \times 5 \times 1 + 1) \times 16$

بازای هر فیلتر یک پارامتر بایاس داریم
 $\Rightarrow 416 = \text{تعداد پارامترها} \rightarrow (16, 220, 220)$: ابعاد خروجی \rightarrow $\frac{224-5}{1} + 1 = 220$

2) $32 \times \text{conv}(5 \times 5)$: تعداد پارامترها $= (5 \times 5 \times 16 + 1) \times 32 = 12832$

$\rightarrow \frac{220-5}{1} + 1 = 216 \rightarrow (32, 216, 216)$: ابعاد خروجی

3) $\text{max pooling}(5 \times 5, \text{stride}=(2, 2))$: پارامتری ندارد maxpooling

$\rightarrow \frac{216-5}{2} + 1 = 105 \rightarrow 105 + 1 = 106 \rightarrow (32, 106, 106)$: ابعاد خروجی

4) $32 \times \text{conv}(5 \times 5)$: تعداد پارامترها $= (5 \times 5 \times 32 + 1) \times 32 = 25632$

$\rightarrow \frac{106-5}{1} + 1 = 102 \rightarrow (32, 102, 102)$: ابعاد خروجی

5) $64 \times \text{conv}(5,5)$: تعداد پارامترها = $(5 \times 5 \times 32 + 1) \times 64 = 51264$

→ ظاهر خروجی: $\frac{102 - 5}{1} + 1 = 98 \rightarrow (64, 98, 98)$

6) $\text{maxpooling}(5 \times 5, \text{stride}=(2,2))$ پارامتر ندارد

→ ظاهر خروجی: $\frac{98 - 5}{2} + 1 = 46,5 + 1 \rightarrow 46 + 1 = 47 \rightarrow (64, 47, 47)$

7) $64 \times \text{conv}(5 \times 5)$: تعداد پارامترها = $(5 \times 5 \times 64 + 1) \times 64 = 102464$

→ ظاهر خروجی: $\frac{47 - 5}{1} + 1 = 43 \rightarrow (64, 43, 43)$

8) $128 \times \text{conv}(5 \times 5)$: تعداد پارامترها = $(5 \times 5 \times 64 + 1) \times 128 = 204928$

→ ظاهر خروجی: $\frac{43 - 5}{1} + 1 = 39 \rightarrow (128, 39, 39)$

9) $\text{maxpooling}(5 \times 5, \text{stride}=(2,2))$: پارامتر ندارد

→ ظاهر خروجی: $\frac{39 - 5}{2} + 1 = 18 \rightarrow (128, 18, 18)$

می باشد دایتا خروجی لایه قبل را در صورت تسلسی است را

به بردار تبدیل کنیم. سپس هر دو زدن به صورت

دلال است

$\Rightarrow 128 \times 18 \times 18 = 41472 = \text{تعداد پارامترها} = 1024 (41472 + 1)$

→ ظاهر خروجی: $(1024) = 42468552$ bias

11) $FC(100)$ = تعداد پارامترها = $100 (1024 + 1) = 102500$

→ ظاهر خروجی: (100)

10 بیشترین تعداد پارامترها در این لایه FC آتفاق مانند یعنی بیش

Network 2 : 1) $128 \times \text{conv}(5 \times 5) \rightarrow$ تعداد پارامترها = $(5 \times 5 \times 1 + 1) \times 128$

→ ظاهر خروجی: $\frac{224 - 5}{1} + 1 = 220 \rightarrow (128, 220, 220) = 3328$

2) $64 \times \text{conv}(5 \times 5)$: تعداد پارامترها = $(5 \times 5 \times 128 + 1) \times 64 = 204864$

→ ظاهر خروجی: $\frac{220 - 5}{1} + 1 = 216 \rightarrow (64, 216, 216)$

3) maxpooling (5×5 , stride = $(2, 2)$) \rightarrow پارامتر تدارد
 حاصله در نتیجه $\frac{216-5}{2} + 1 = 105,5 + 1 \rightarrow 105 + 1 = 106$
 $\Rightarrow (64, 106, 106)$

4) $64 \times \text{conv}(5 \times 5)$: تعداد پارامترها = $(5 \times 5 \times 64 + 1) \times 64 = 102464$
 $\rightarrow \frac{106-5}{1} + 1 = 102 \rightarrow (64, 102, 102)$: ابعاد خروجی

5) $32 \times \text{Conv}(5 \times 5)$: تعداد پارامترها = $(5 \times 5 \times 64 + 1) \times 32 = 51232$
 $\rightarrow \frac{102-5}{1} + 1 = 98 \rightarrow (32, 98, 98)$: ابعاد خروجی

6) maxpooling : ابعاد خروجی / پارامتر تدارد $\rightarrow \frac{98-5}{2} + 1 = 46,5 \rightarrow (32, 47, 47)$
 روش حساب

7) $32 \times \text{conv}(5, 5)$: تعداد پارامتر = $(5 \times 5 \times 32 + 1) \times 32 = 25632$
 $\rightarrow \frac{47-5}{1} + 1 = 43 \rightarrow (32, 43, 43)$: ابعاد خروجی

8) $16 \times \text{Conv}(5, 5)$: تعداد پارامتر = $(5 \times 5 \times 32 + 1) \times 16 = 12816$
 $\rightarrow \frac{43-5}{1} + 1 = 39 \rightarrow (16, 39, 39)$: ابعاد خروجی

9) maxpooling : ابعاد خروجی / پارامتر تدارد $\rightarrow \frac{39-5}{2} + 1 = 18 \rightarrow (16, 18, 18)$

10) $FC(1024) \rightarrow$ خروجی لایه تبل \rightarrow flatten! $16 \times 18 \times 18 = 5184$
 که هر سکه از این نورول ها ب 1024×1024 نورون دارد و میتواند \Rightarrow تعداد پارامترها = $(5184 + 1) \times 1024 = 5309440$

Vazik \rightarrow ابعاد خروجی : (1024)

$$11) FC(100) = 1024 + 1 \times 100 = 102500$$

→ تعداد پالامترها : $(1024+1) \times 100 = 102500$

→ ابعاد خروجی : (100)

لایه اول FC بینیتین پالامتر را تحمیل کند یعنی لایه شماره 10 ←

لایه های FC تعداد پالامترهای زیادی را بثسمد و تحمیل می کنند ←

نهاده در قسمت ب ب هستم برسی هر لایه انجام شد

ث) با توجه به آنکه سایز تعیاونیر نباشد (وقتی می نبینیم چون در صورت انتقال سیگنال

در لایه های مختلف در حافظه حراری می تجزد، برای فقط سایز تعیاونیر مورد محبت است همان آن
که در نظر گرفته شده از در نظر گرفتن

هر دو مدل حافظه مردد بیان (حسابی نیم) پالامترها خود را که در عین

$$\begin{aligned} & 220^2 \times 16 + \\ & = 224^2 \times 1 + \sqrt{216^2 \times 32 + 106^2 \times 32 + 102^2 \times 32 + 98^2 \times 64} \\ & + 47^2 \times 64 + 43^2 \times 64 + 39^2 \times 128 + 18^2 \times 128 + 1024 + 100 \end{aligned}$$

$$\begin{aligned} & 224^2 \times 1 + \\ & = \sqrt{220^2 \times 128 + 216^2 \times 64 + 106^2 \times 64 + 102^2 \times 64 + 98^2 \times 32} \\ & + 47^2 \times 32 + 43^2 \times 32 + 39^2 \times 16 + 18^2 \times 16 + 1024 + 100 \end{aligned}$$

+ مجموع تعداد در مدل دوم () تعداد در مدل اول

\Rightarrow مدل اول حافظه کمتری را در این اسفاده فراهم می کند. در نتیجه مناسب تر

آنکه در مطالعه مدل اول مطالعه مدل دوم را نمایم.

Vazik اسفت